


Detección Temprana de *Hits* Musicales en México

De Viral 50 → Top 200: Decodificando las Señales Estadísticas del Éxito Musical Mexicano



Analista: Ing. Zadkiel Zerpa

Diplomado: Ciencia de Datos (UNAM - Emisión 12)

Directores: Ing. Héctor Bautista & Dr. Omar Mendoza

Fecha: 20 de Febrero de 2026

Objetivo de Negocio: Análisis Estratégico
para Priorización de Inversión de A&R y
Marketing

Resumen Ejecutivo (TL;DR)

1. Problema



Miles de canciones entran al Viral 50 anualmente, donde la probabilidad azarosa de consolidarse en el Top 200 es del 13.5%. Invertir en la compra de catálogo o en estrategias de Marketing reactivo sobre tracks efímeros o "falsos positivos" es muy costoso para las disqueras.

2. Soución (El Modelo)

Trayectoria en
Charts Spotify



Interacciones
en Youtube



Características
de Audio



Gradient
Boosting



Se generó un motor de Machine Learning que integra 3 fuentes de datos: Las trayectorias en Spotify, las características del Audio e interacciones en YouTube

3. Resultados



Se generó una herramienta de priorización con una precisión del 60% para clasificar al Top 5 viral que pasará al Top 200. Resultado que mejora x4 la probabilidad del azar

Es imposible predecir el futuro con certeza absoluta pero podemos reducir la incertidumbre en oportunidades de decisión rápida

Hipótesis y Lógica de Negocio


Hipótesis General

El salto de Viral 50 → Top 200 **no** es aleatorio y deja huellas o pistas que nos permiten predecir su transición.


Oportunidad de Negocio

La industria musical requiere mucha intuición o conocimiento del negocio al momentos de hacer inversiones rápidas y acertadas.

Sin embargo, a veces el juicio del experto puede estar sesgado o no tener en consideración viralizaciones con poco días en el mercado. Por ello, el modelo lo que busca es ser una herramienta de apoyo a la intuición humana.



Arquitectura General del Sistema




Entrenamos con target 0/1 pero la salida operativa no es "hit / no hit" sino un ranking ordenado por probabilidad, tomando las top-K canciones.

Ingeniería de Características

¿Qué Define a un Candidato para saltar de Viral 50 → Top 200?

1. Comportamiento en Charts

1. best_rank
2. days_on_viral
3. rank_slope



Movimiento en Charts

¿Captura sube el momentum rápido?
¿Se mantiene?

2. Características de Audio

1. danceability
2. energy
3. valence
4. tempo




Percepción Sonora

¿Es bailable? ¿Es triste o alegre?

3. Interacciones en Youtube

1. yt_comment_ratio
2. yt_max_views
3. yt_like_ratio




Validación Social

¿Tiene comentarios?
¿Tiene vistas?

Total de 23 variables procesadas y escaladas (StandardScaler) para eliminar sesgos de magnitud


Línea Base Probabilística (El Baseline)

- A pesar de tener datasets con más de 100K tracks aleatorios tanto en Spotify como en YouTube, sólo logramos hacer match de aprox. ~1K canciones entre datasets.
- De esas ~1K canciones sólo 140 pasaron de Viral 50 → Top 200 México en el año fiscal 2021
- Por ese motivo nuestra línea base estadística es cercana al ~13%




Análisis Exploratorio - No Supervisado

El problema NO es lineal
Los clusters están mezclados
(Entra o no entra al Top 200)



Clusters Virales
Se ven 3 tipos de canciones virales
(Clusters 0, 1 y 2)



Tipos de Clusters Virales

Cluster 0: Viral Fugaz (Hit Rate: 7%)

Canciones con breve permanencia en charts y bajo engagement social.

Cluster 1: Alta Viralidad (Hit Rate: 19%)

Rápido ascenso en charts, alta viralidad inicial pero menor retención a largo plazo.

Cluster 2: Viral Sostenido (Hit Rate: 20%)

Crecimiento gradual en charts y alto engagement social

Modelos Propuestos y Configuración General

	Modelo	Descripción General
1	Regresión Logística	Baseline interpretable pero limitada en complejidad
2	Árbol de Decisión	Reglas simples pero propenso a overfitting
3	Random Forest	Ensamble de árboles robusto y reduce varianza
4	Gradient Boosting	Optimización secuencial de árboles con mejor manejo del desbalance

Configuración Técnica General

Partición:


1. Train (60%)
2. Validation (20%)
3. Test (20%)

Estrategia:

Para penalizar errores en clases minoritarias

- `class_weight = balanced`


Evaluación de los Modelos



Modelo	AUC
Gradient Boosting	0.724 (Mejor Discriminación)
Random Forest	0.66
Regresión Logística	0.64
Árboles de Decisión	0.59

Gradient Boosting domina consistentemente, ofreciendo el mejor equilibrio entre Tasa de Verdaderos Positivos y Falsos Positivos.

¿Qué Variables Predicen el Éxito Viral?




Se puede apreciar que:


1. El comportamiento directamente de los charts de Spotify tiene una relevancia predictiva muy fuerte
2. Los comentarios en YouTube tienen mayor peso que los views.
3. Si una canción es en vivo o si es muy bailable tienen inclusive mayor o igual peso que los views de YouTube

Desempeño en el "Mundo Real" (Set Test)

- **ROC-AUC Test:** 0.719 (Consistente, sin overfitting)
- **True Negatives (176):** El Modelo es *Conservador*. Prefiere estar muy seguro de que será Hit antes de recomendar malas inversiones



- **Precision@5 = 60%**
- Si el modelo recomienda 5 canciones entonces 3 serán Hits seguros.
- Esto representa x4 una mejor probabilidad que el simple azar (13.5%).



No necesitamos clasificar todo el universo. Solo necesitamos un Top 5 confiable para concentrar el presupuesto.

Recomendaciones Estratégicas de Negocio

Lista Semanal Top 5 Picks

Entrega automática de lista curada al equipo de A&R y Marketing cada lunes.



Herramienta de Soporte

El Ranking de Probabilidad es una herramienta de soporte para validar o detectar oportunidades y que siempre debe ir de la mano con el conocimiento de negocio



Enfoque en Cluster 2


- Éste es el perfil con ascenso sostenido y alta permanencia en los charts
- Se recomienda Inversión fuerte ya que es el candidato ideal para conversión a Top 200.



Conclusiones y Puntos de Mejora del Modelo

Resumen de Impacto

- **Viabilidad Posible:** El salto a Top 200 es predecible ($AUC > 0.70$).
- **Eficiencia:** La herramienta multiplica x4 la precisión en el Top 5 vs Azar.



Trabajo Futuro

- Validar con data post-pandemia (Datos 2022+)
- Integrar el ISRC para matching perfecto de canciones entre plataformas
- Incorporar señales de TikTok.



GRACIAS

¿Dudas o Preguntas?