



DIPLOMADO DE CIENCIA DE DATOS EMISIÓN 12

Detección Temprana de Hits en México: de Viral 50 a Top 200 con Señales de YouTube y Spotify

PROYECTO FINAL

Para optar al diploma de

CIENTIFICO DE DATOS

Presenta

ZADKIEL DAVID ZERPA MÉNDEZ

CODIRECTOR DE PROYECTO: ING. HÉCTOR BAUTISTA

CODIRECTOR: DR. OMAR MENDOZA GONZÁLEZ

CIUDAD DE MÉXICO, Feb 2026

ÍNDICE DE CONTENIDO

1. Título.....	4
2. Resumen.....	4
3. Introducción.....	4
4. El Problema.....	5
5. Propósito del Estudio.....	5
6. Descripción del Proyecto.....	6
7. Hipótesis.....	6
8. Flujo de Trabajo.....	6
9. Mapeo del sistema.....	7
Actores y Usuarios del Sistema.....	7
Entradas (Inputs de Datos).....	8
Procesos.....	8
Salidas (Outputs).....	9
Decisiones de Negocio (Warner Music).....	9
Supuestos y Limitaciones del Sistema.....	10
10. Definición de Métricas Adecuadas.....	10
11. Métodos y Modelos.....	11
Estrategia metodológica.....	11
Construcción del dataset analítico.....	12
Modelos supervisados.....	13
Modelos no supervisados (exploratorio).....	14
1. Análisis de Componentes Principales (PCA):.....	14
2. K-Means Clustering.....	14
12. Evaluación de Modelos.....	15
Protocolo de evaluación.....	15
Resultados en validación.....	15
Precision@K.....	16
Evaluación final con el conjunto de prueba (Test).....	16
Síntesis.....	17
13. Análisis.....	17
Contraste con las hipótesis.....	17
Interpretación del modelo como herramienta de priorización.....	19
Limitaciones del estudio.....	19
Comparación con la literatura.....	20
14. Resultados.....	20
Resultados del modelo predictivo.....	20
Variables más relevantes.....	20
Segmentación de comportamientos.....	21

Entregables del proyecto.....	21
15. Conclusiones y Recomendaciones.....	22
Conclusiones.....	22
Recomendaciones.....	22
Trabajo futuro.....	23
Referencias Electrónicas y Fuentes de Datos.....	24
I. Artículos científicos.....	24
II. Datasets públicos a utilizar para el proyecto.....	24

1. Título

Detección temprana de hits en México: de Viral 50 a Top 200 con señales de YouTube y Spotify

2. Resumen

Este proyecto propone un enfoque de ciencia de datos para detectar tempranamente canciones con alta probabilidad de convertirse en “hits” en México, entendidos como *tracks* que transitan desde una fase de tracción temprana (Spotify Viral 50 MX) hacia una fase de consumo masivo (Spotify Top 200 MX). La hipótesis central es que esta transición puede anticiparse combinando tres tipos de señales:

1. Dinámica temprana en charts de Spotify (posición, streams y velocidad de crecimiento)
2. Audio features (p. ej., danceability, energy, valence, tempo)
3. Métricas de interacción en YouTube Trending México (views, likes, comentarios y razones de engagement).

Se construirá un dataset integrado para la ventana del año fiscal 2021 (2020-08-12 a 2021-11-30), y se formulará el problema como clasificación supervisada binaria (logra o no logra entrar a Top 200 dentro de un horizonte temporal). Se compararon modelos base e interpretables (regresión logística) contra modelos no lineales (árboles, random forest y boosting) y se complementará con análisis no supervisado (PCA y clustering) para segmentar “tipos” de comportamiento musical. El resultado esperado es un modelo con desempeño superior a baselines simples (p. ej. streams o views), junto con insights accionables para priorizar inversión de marketing y estrategia cross-plataforma.

3. Introducción

En el mercado musical digital, la atención es altamente competitiva y los “hits” surgen a partir de señales tempranas que pueden observarse en plataformas de streaming y video. Spotify y YouTube son especialmente relevantes en México: Spotify refleja consumo de audio recurrente, mientras que YouTube captura consumo audiovisual y señales sociales (interacción, discusión, compartidos). Identificar de forma temprana qué canciones tienen probabilidad de consolidarse permite optimizar recursos de marketing, timing de contenidos y decisiones de priorización.

Un punto crítico es diferenciar entre tracción temprana y popularidad consolidada. Spotify describe que sus Viral charts capturan canciones con “buzz” considerando factores como subida reciente en plays, shares y descubrimiento reciente, lo cual los vuelve un proxy de momentum temprano. Por otro lado, el listado del Top 200 refleja un consumo más masivo. Por ello, la transición de Viral 50 → Top 200 se usa aquí como una definición operacional de salto a *mainstream*.

Este proyecto busca transformar datos públicos y reproducibles en un enfoque analítico formal: construir un dataset integrado, diseñar un target con control de fuga de información, entrenar modelos comparables y traducir resultados en recomendaciones aplicables a una disquera.

4. El Problema

La viralidad temprana de una canción no garantiza su conversión en un consumo sostenido a largo plazo, lo que plantea un desafío clave en la asignación eficiente de recursos de inversión. Dado que no todos los lanzamientos justifican el mismo nivel de impulso promocional, resulta necesario distinguir entre señales de *buzz* inicial (como las reflejadas en rankings de viralidad de Spotify) y evidencias de adopción más amplia y estable (como la presencia en listados de consumo general) para encontrar patrones de asociación y delimitar una heurística que permita redirigir financiamiento o esfuerzos de Marketing de manera temprana.

En este contexto, plataformas audiovisuales como YouTube pueden ofrecer indicadores tempranos de adopción a través del engagement y el consumo de video, incluso antes de que dichos patrones se manifiesten plenamente en plataformas de streaming de consumo general. Por ello, se vuelve indispensable el desarrollo de una metodología cuantitativa que sea reproducible, explicable y orientada a la priorización estratégica de apuestas musicales.

5. Propósito del Estudio

Construir y evaluar un modelo que estime la probabilidad de que una canción con tracción temprana (Viral 50 MX) se convierta en hit consolidado (entrada a Top 200 MX en horizonte de tiempo H), usando señales de Spotify, YouTube y audio features.

Objetivos específicos:

- Definir un target robusto “Viral → Top200” sin leakage.
- Comparar modelos supervisados (logística, árboles, random forest, boosting).
- Evaluar con métricas apropiadas (AUC, F1, Precision@K).

- Identificar variables relevantes y segmentar comportamientos (PCA/clustering).

6. Descripción del Proyecto

El proyecto consiste en la integración y análisis de múltiples conjuntos de datos provenientes de plataformas digitales relevantes para el consumo musical en México, incluyendo rankings de Spotify, tendencias de YouTube y características acústicas de las canciones. A partir de esta integración, se desarrollará un proceso de ingeniería de características orientado a capturar señales tempranas de desempeño, tales como la dinámica inicial de crecimiento, ratios de engagement y atributos de audio. Con base en estas variables, se entrenarán y evaluarán distintos modelos predictivos, cuyos resultados serán comparados contra enfoques base (baselines) para medir su valor incremental. Finalmente, el proyecto entregará como resultados un modelo analítico interpretable, acompañado de casos de estudio y recomendaciones prácticas que apoyen la toma de decisiones estratégicas en la priorización de lanzamientos musicales.

7. Hipótesis

- **H1:** Canciones que logran saltar de Viral 50 a Top 200 presentan mayor momentum temprano en Spotify (mejor ranking temprano y mayor crecimiento de streams) que las que no saltan.
- **H2:** Métricas de engagement en YouTube (likes/views, comments/views y crecimiento temprano) aportan señal incremental para predecir el salto, frente a usar solo Spotify/audio.
- **H3:** Existen “perfiles” (clusters) de canciones donde aparecen ciertos patrones (p. ej. alta energía + alto engagement) muestran mayor probabilidad de consolidación *mainstream*.

8. Flujo de Trabajo

A continuación se van a enumerar y describir brevemente cada uno de los pasos realizados en el proyecto que forman parte del flujo de trabajo realizado

1. **Ingesta de datos (datasets procesados):** carga de tablas en formato Parquet desde repositorio propio (Spotify Charts MX ventana 2020-08-12 a 2021-11-30, audio features unificados, y YouTube Trending MX en 3 partes).

2. **Normalización y limpieza:** estandarización de fechas, tipos de datos y llaves (track_id, video_id), eliminación de duplicados y columnas auxiliares, y tratamiento de valores faltantes.
3. **Construcción del target (variable objetivo):** definición operacional del evento “hit” como transición de Viral 50 MX a Top 200 MX dentro de un horizonte temporal definido. Etiquetado binario por canción.
4. **Ingeniería de características:**
 - a. Señales de Spotify charts (trayectoria: rank, permanencia, velocidad de crecimiento de streams).
 - b. Audio features (danceability, energy, valence, tempo, loudness, etc.).
 - c. Señales de YouTube (views, likes, comment_count y razones likes/views, comments/views).
5. **Partición train/validation/test con control temporal:** separación cuidando fuga de información (evitar que datos “futuros” entrenen el modelo).
6. **Modelado supervisado:** entrenamiento y comparación de regresión logística, árboles, Forest, boosting y selección del mejor modelo por métricas.
7. **Análisis no supervisado (apoyo interpretativo):** PCA para visualización y clustering (K-means) para segmentar tipos de canciones y comparar propensión a “hit”.
8. **Evaluación y explicación:** métricas (ROC-AUC, F1, Precision/Recall, Precision@K), matriz de confusión, y análisis de importancia de variables.
9. **Síntesis de hallazgos y recomendaciones:** resultados accionables para priorización temprana (playlisting, inversión de marketing, estrategia audiovisual).

9. Mapeo del sistema

El proyecto se puede entender como un sistema analítico que integra señales tempranas de popularidad en Spotify (Viral 50 MX), señales de consolidación de consumo masivo (Top 200 MX) y señales de engagement en YouTube, con el objetivo de estimar la probabilidad de que una canción “salte” de Viral 50 a Top 200 en una ventana temporal definida.

Actores y Usuarios del Sistema

1. **A&R (Artists & Repertoire):** Identificación temprana de canciones con potencial de consolidación (“hits”) y priorización de seguimiento.
2. **Marketing / Digital / Growth:** Priorización de inversión (paid media, contenido, colaboraciones, playlisting, estrategia audiovisual).

3. **Equipo de Data & Insights:** Mantenimiento del pipeline, monitoreo de desempeño del modelo, y generación de reportes interpretables.

Entradas (Inputs de Datos)

1. Spotify Charts MX (Viral 50 + Top 200)

- a. Con ventana de tiempo anual: Para el presente estudio se hará dentro del año fiscal del año 2021 con un margen extra de tiempo en ambos extremos de inicio a fin de año fiscal 2021 → 2020-08-12 a 2021-11-30
- b. Las variables principales a analizar serán: date, chart, ranking, streams, track_id, artista y título.
- c. Esto nos permitirá construir la trayectoria temporal del desempeño del track y definir el evento objetivo (salto Viral → Top 200).

2. Audio features y metadatos

- a. Variables con tipo de musicalidad por ejm: danceability, energy, valence, tempo, loudness, acousticness, etc.
- b. Estas variables pueden aportar señales “intrínsecas” del track (perfil sonoro) + metadatos.

3. YouTube Trending México

- a. Con ventana de tiempo igual 2020-08-12 a 2021-11-30
- b. Las variables principales a analizar serán: view_count, likes, comment_count, channelTitle, title, publishedAt.
- c. Esto podrá aportar señales de engagement temprano y momentum de consumo audiovisual.

Procesos

1. **Ingesta:** Carga de tablas desde repositorio (formato Parquet; YouTube dividido en partes por tamaño).
2. **Normalización:** Estandarización de fechas, tipos y llaves (track_id, video_id) y limpieza de inconsistencias.
3. **Construcción del target (variable objetivo):**
 - a. Para cada track que aparece en Viral 50 MX, se etiqueta como:
 - i. Clase 1: si entra a Top 200 MX dentro de un horizonte definido.
 - ii. Clase 0: si no entra a Top 200 en ese horizonte.
4. **Ingeniería de características**
 - a. **Spotify:** permanencia en Viral, mejor ranking, velocidad de crecimiento, streams máximos/promedios, etc.
 - b. **YouTube:** métricas brutas (views/likes/comments) y derivadas (likes/views, comments/views), y agregaciones por semana/periodo.

- c. **Audio:** features del track (perfil sonoro).
- 5. **Integración Spotify-YouTube**
 - a. Para este proyecto en específico se va a hacer un emparejamiento cuando sea posible (por reglas y criterios de similitud sobre title/artist vs title/channel, y filtros de calidad). Sin embargo, la regla de integración de este modelo en producción formal sería a través del identificador único universal de cada canción, llamado ISRC.
- 6. **Modelado**
 - a. Se ejecutará un entrenamiento de modelos supervisados (baseline + árboles o boosting) para predecir Clase 1 vs Clase 0. Así como modelos no supervisados (PCA + clustering) para segmentación e interpretación.
- 7. **Evaluación e interpretación**
 - a. Las métricas de evaluación del modelo serán: ROC-AUC, F1, Precision/Recall, y Precision@K, para analizar la importancia de variables y lectura de errores.
- 8. **Salida final**
 - a. Se tendrá como producto final un ranking de tracks con probabilidad de salto al top 200 e insights interpretables.

Salidas (Outputs)


1. **Probabilidad estimada:** de transición Viral 50 → Top 200 para cada track elegible.
2. **Top-K recomendaciones:** (ej. “los 20 tracks con mayor probabilidad de consolidación”).
3. **Explicaciones e insights:** variables más relevantes, perfiles/clusters con mayor probabilidad.

Decisiones de Negocio (Warner Music)

1. **Priorización temprana de inversión** en campañas (marketing, contenido, o pauta digital).
2. **Activación audiovisual (YouTube)** como palanca anticipada cuando el modelo detecta señales de consolidación.
3. **Alineación A&R + Marketing** con criterios cuantitativos para decidir dónde apostar primero en caso redirección de budget donde haya alto potencial de éxito temprano.

Supuestos y Limitaciones del Sistema.

1. **No todos los track_id tienen audio features** completos (cobertura parcial por fuente).
2. **El emparejamiento Spotify-YouTube puede introducir ruido** (títulos similares, contenidos no musicales, etc.), por lo que se aplicarán reglas de calidad.
3. **El modelo se entrena en una ventana temporal específica** por lo que su generalización a otros periodos requeriría re-entrenamiento/validación adicional.



Esquema del Mapeo del sistema

10. Definición de Métricas Adecuadas

1. **Métrica principal del fenómeno (definición de éxito):** En este estudio se define como “éxito” o consolidación en mainstream cuando una canción después de aparecer en Viral 50 México, logra entrar a Top 200 México dentro de un horizonte temporal $H = 28$ días. Esta definición permite separar la viralidad temprana (momentum) del consumo sostenido y masivo (Top 200).
2. **Métricas de desempeño del modelo (clasificación):** Dado que el objetivo es predecir una variable binaria (salta o no salta al top), y considerando que la clase positiva puede ser minoritaria, se utilizarán las siguientes métricas:
 - a. **ROC-AUC:** Mide capacidad de discriminación global del modelo sin fijar un umbral único y nos va a servir para comparar entre modelos.
 - b. **Precision (clase positiva):** Ésta métrica nos va a ayudar a identificar dentro de las canciones predichas como *candidatas a saltar* ¿qué

proporción realmente salta? Esto es muy relevante de medir para no invertir en falsas candidatas.

- c. **Recall (clase positiva)**: Ésta métrica nos va a ayudar a identificar dentro del umbral de todas las canciones que sí saltan, ¿cuántas detecta el modelo? Igualmente, es muy relevante porque perder un hit potencial es un costo de oportunidad.
 - d. **F1-score**: Esta métrica medirá el balance entre *precision* y *recall* en la clase positiva, nos va a servir para discriminar el desempeño en momentos de desbalance.
3. **Métricas de desempeño orientadas a priorización (ranking)**: En un contexto de discográfica, la salida más accionable suele ser un Top-K de canciones para priorizar inversión. Por ello se incorporan métricas tipo ranking:
- a. **Precision@K**: De las $K = 20$ canciones con mayor probabilidad predicha, cuántas efectivamente saltan a Top 200.
 - b. **Recall@K**: Qué proporción de todos los “hits” reales queda capturada dentro del Top-K (20 canciones).
4. **Métricas derivadas para ingeniería de características (señales tempranas)**: Para capturar *momentum* y desempeño temprano, se construirán variables cuantitativas y sus agregaciones por periodo:
- a. **Spotify (Viral 50)**: Mejor posición alcanzada, días en el chart, tendencia de streams, pendiente de crecimiento (slope), volatilidad.
 - b. **YouTube**: Views, likes, comments e interacciones como likes/views, comments/views, así como cambios por periodo para aproximar crecimiento.
5. **Métricas de control de calidad (integración Spotify & YouTube)**: Dado que el enlace entre plataformas no siempre tiene llaves universales disponibles, se implementarán métricas de control para evaluar la confiabilidad del *emparejamiento*:
- a. **Cobertura de matching**: Porcentaje de tracks con emparejamiento válido Spotify → YouTube.
 - b. **Validación de calidad (muestreo)**: Revisión manual de una muestra aleatoria de matches para estimar tasa de falsos emparejamientos y ajustar reglas.

11. Métodos y Modelos

Estrategia metodológica

La estrategia metodológica se diseñó para resolver un problema de clasificación binaria con datos multifuente y cobertura desigual, manteniendo un pipeline reproducible y

comparable entre enfoques y modelos. Se construyó un dataset analítico por track (*track_id*) integrando señales de desempeño en rankings (Charts), atributos acústicos (Audio) y *engagement* (YouTube).

Se incorporaron flags binarios para representar explícitamente la disponibilidad de *match* de la canción entre datasets y manejar casos con información parcial. Para evitar sesgos y asegurar consistencia, se aplicó partición estratificada en entrenamiento/validación/prueba y preprocesamiento estandarizado (escalamiento ajustado solo en entrenamiento).

El modelado supervisado se abordó mediante *benchmarking* de familias de modelos con distinta complejidad (lineales, árboles y ensambles), usando ponderación de clases para mitigar el desbalance. Finalmente, se añadió un bloque no supervisado (PCA y clustering sobre variables) con fines exploratorios para entender la estructura del espacio de features y complementar la lectura del fenómeno.

Construcción del dataset analítico

1. **El dataset analítico integra tres fuentes de datos** centradas en el mercado mexicano. La unidad de análisis es el track único identificado por el **track_id** de Spotify. Se registraron 1,045 tracks únicos en Viral 50 MX que entran al top 200 durante la ventana de observación (agosto 2020 - noviembre 2021).
2. **La variable objetivo (1)**
 - a. **Clase (1)**: El track salta de Viral 50 → Top 200 dentro de un horizonte $H = 28$ días
 - b. **Clase (0)**: Donde el track no salta de viral al top.
 - c. **La tasa de clase positiva (1) es del 13.5%**. Esto representa un problema de clasificación con desbalance moderado, sin embargo, debido a que contamos con un dataset muy pequeño, era un resultado esperado.
3. **Ingeniería de características** por fuente de datos:

Fuente	Features	Descripción
Spotify Charts (6 características)	best_rank, worst_rank, mean_rank, days_on_viral, rank_range, rank_slope	Esta fuente representa la trayectoria del track que pasa del listado Viral 50 al top 200. Los features o características presentes en esta fuente son: mejor posición, permanencia, volatilidad y tendencia temporal del ranking. Éstas features tienen un 100% de cobertura.

Audio Features (10 características)	danceability, energy, valence, tempo, loudness, acousticness, speechiness, instrumentalness, liveness, popularity	La fuente nos muestra características acústicas y de popularidad. La identificación entre datasets se busca por track_id, artista o título. La cobertura de identificación entre datasets es del ~25%.
YouTube Trending (5 características)	yt_max_views, yt_max_likes, yt_max_comments, yt_like_ratio, yt_comment_ratio	Métricas de engagement del video musical. Se hace el <i>Matching</i> en 3 niveles (título exacto, contenido, artista+título). La cobertura entre datasets es del ~47%.
Flags binarias (2 características)	has_audio_features, has_youtube_match	Indicadores de disponibilidad de datos creados como campos auxiliares para ver el <i>flag</i> de los datos de Spotify con match

4. **Las características relevantes** encontradas suman un total de **23**.
5. **Partición estratificada**: 60% entrenamiento (627), 20% validación (209), 20% prueba (209).
6. **Escalamiento** con *StandardScaler* ajustado sobre el conjunto de entrenamiento.

Modelos supervisados

1. Se entrenaron cuatro clasificadores binarios con *class weight* = “balanced” para compensar el desbalance de clases.
2. Todos usan *random state* = 42 para reproducibilidad.

Modelo	Hiperparámetros	Justificación
Regresión Logística	solver=lbfgs, max_iter=1000, class_weight=balanced	Baseline lineal. Interpretable mediante coeficientes.
Árbol de Decisión	max_depth=5, class_weight=balanced	Genera reglas explícitas tipo: si best_rank < 10 y days_on_viral > 20, entonces hit .

Random Forest	n_estimators=200, max_depth=8, class_weight=balanced	Ensamble de árboles que reduce varianza. Permite medir la importancia de variables.
Gradient Boosting	n_estimators=200, max_depth=4, learning_rate=0.1	Ensemble de árboles secuenciales que optimiza errores residuales.

Modelos no supervisados (exploratorio)

1. Análisis de Componentes Principales (PCA):

- Se aplicó para visualizar la estructura del espacio de features en dos dimensiones. Los dos primeros componentes capturan aproximadamente ~30% de la varianza total, lo cual es esperable dado que las 23 features provienen de tres fuentes heterogéneas (posición en charts, características acústicas y engagement en YouTube) que miden aspectos distintos del fenómeno.
- Se requieren 13 componentes para alcanzar el 90% de varianza acumulada.
- La proyección en 2D muestra solapamiento parcial entre clases, confirmando que el problema no es linealmente trivial y justifica el uso de modelos no lineales.

2. K-Means Clustering

- K-Means se aplicó exclusivamente sobre las 6 features de Charts ya que tiene 100% de cobertura.
- El número óptimo de clusters se seleccionó mediante el coeficiente de silueta, resultando en k=3 con silhouette=0.43. Los tres clusters revelan perfiles interpretables:

Cluster	Perfil	Tracks	Hit rate
0	Ranking bajo (~36), poca permanencia (~11 días), rango estrecho.	~308	~7%
1	Ranking alto (~10), poca permanencia, rango estrecho. Entra alto y se va rápido.	~75	~19%

2	Ranking alto (~10), alta permanencia (~44 días), rango amplio. Sube gradualmente.	~244	~20%
---	---	------	------

12. Evaluación de Modelos

Protocolo de evaluación

La evaluación siguió un protocolo en dos etapas diseñado para evitar sobreajuste en la selección del modelo. Primero, los cuatro modelos entrenados en el Capítulo 11 se evaluaron sobre el conjunto de validación (209 muestras, 20%) para seleccionar el mejor. Segundo, el modelo ganador se evaluó sobre el conjunto de prueba (test, 209 muestras, 20%), reservado exclusivamente para esta estimación final.

Dado el desbalance de clases (13.5% positivos, 86.5% negativos), el *accuracy* por sí sola no es informativo. Por ello se emplearon cinco métricas complementarias: ROC-AUC como criterio principal de selección (mide capacidad discriminativa independiente del umbral), *Precision* (proporción de aciertos entre las predicciones positivas), *Recall* (proporción de hits reales detectados), *F1-Score* (media armónica de *precision* y *recall*), y *Precision@K* (precisión sobre las K-canciones con mayor probabilidad predicha, que simula el escenario operativo real).

Resultados en validación

La siguiente tabla resume el desempeño de los cuatro modelos en el conjunto de validación:

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Reg. Logística	0.603	0.198	0.643	0.303	0.640
Árbol de Decisión	0.546	0.187	0.714	0.296	0.592
Random Forest	0.813	0.177	0.107	0.133	0.660
Gradient Boosting	0.842	0.308	0.143	0.195	0.724

Se observan dos comportamientos contrastantes. Los modelos simples (Regresión Logística y Árbol de Decisión) alcanzan *recall* alto (0.64-0.71) a costa de precisión muy baja (~0.19). Por ello, detectan la mayoría de los hits, pero generan demasiadas falsas alarmas.

Los modelos (Random Forest y Gradient Boosting) priorizan precisión sobre recall. Estos modelos cuando predicen un hit, aciertan más frecuentemente, pero dejan escapar muchos hits reales. **Gradient Boosting** obtuvo el mayor ROC-AUC (0.724), lo que indica la mejor capacidad de ordenamiento global, y fue seleccionado como modelo final.

Las curvas comparativas entre modelo (ROC) confirman visualmente esta jerarquía donde **Gradient Boosting** domina al resto. Éste modelo tiene su curva consistentemente por encima de los demás modelos, especialmente en la zona de baja tasa de falsos positivos ($FPR < 0.4$). Las curvas Precision-Recall muestran que Gradient Boosting también tiene el mayor Avg. de *Precision* ($AP=0.252$), indicando que mantiene precisión razonable a medida que incrementa el recall.

Precision@K

Precision@K es una métrica muy relevante para el caso de uso real. Si un sello discográfico selecciona las K canciones con mayor probabilidad predicha de saltar al Top 200, ¿cuántas realmente lo lograrían?. A continuación se adjunta una tabla mostrando las probabilidades por K-canciones. La línea base (selección al azar) es 13.5%.

Gradient Boosting	P@5	P@10	P@15	P@20	P@25	P@30
Validación	0.200	0.200	0.267	0.250	0.280	0.267
Test	0.600	0.400	0.333	0.300	0.320	0.300

En el conjunto de test, **Gradient Boosting alcanza Precision@5 = 0.60**, es decir, 3 de cada 5 canciones del top-5 recomendado efectivamente saltan a Top 200. Esto es x4 veces superior a la línea base. Para P@10 la probabilidad es de 0.40, es decir, el modelo aprox. triplica el azar. Incluso a K=30, la precisión se mantiene en 0.30 (x2 veces el azar). Estos resultados demuestran que aunque el recall global es bajo, el modelo es altamente efectivo como herramienta de priorización cuando se limita a un número reducido de recomendaciones, algo que en realidad puede resultar muy beneficioso para la optimización y redireccionamiento de inversión de forma temprana.

Evaluación final con el conjunto de prueba (Test)

A continuación se muestra una tabla comparativa de validación entre modelos usando el conjunto de prueba:

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Reg. Logística	0.675	0.230	0.607	0.333	0.717
Árbol de Decisión	0.569	0.196	0.714	0.308	0.595
Random Forest	0.866	0.500	0.143	0.222	0.743
Gradient Boosting	0.857	0.375	0.107	0.167	0.719

El modelo **Gradient Boosting**, fue seleccionado por su excelente ROC-AUC obtenido en validación. Gradient Boosting obtuvo ROC-AUC = 0.719 en test, consistente o muy cercano con su valor obtenido en la etapa de validación (0.724). Esta consistencia confirma la ausencia de sobreajuste en la selección. Su matriz de confusión muestra 176 verdaderos negativos, 3 verdaderos positivos, 5 falsos positivos y 25 falsos negativos. La baja tasa de falsos positivos (5 de 181) se traduce en *Precision* = 0.375, lo que significa que cuando el modelo predice un hit, acierta en 3 de cada 8 casos.

Es notable que Random Forest alcanzó el mayor ROC-AUC en test (0.743), superando a Gradient Boosting a pesar de tener menor AUC en validación. Esto refleja la variabilidad inherente a un conjunto de test pequeño (28 positivos), donde diferencias de 2-3 predicciones correctas alteran significativamente las métricas. La comparación de barras entre validación y test muestra que ambos modelos son competitivos, con AUC consistentemente superior a 0.66.

Síntesis

La evaluación demuestra que es posible predecir el salto de Viral 50 a Top 200 con desempeño sustancialmente superior al azar. Los modelos Forest y GBoost con ROC-AUC 0.66 y 0.74, respectivamente en validación superan consistentemente a los modelos simples (0.59-0.64). La métrica más reveladora es Precision@K, donde el modelo **Gradient Boosting**, logra Precision@5 = 0.60 en test, lo que significa que si se priorizan las 5 canciones con mayor probabilidad 3 de ellas efectivamente saltarán al Top 200. Este hallazgo posiciona al modelo como una herramienta de priorización útil para la industria musical, más que como un clasificador binario convencional.

13. Análisis

Contraste con las hipótesis

- **H1** planteaba que las canciones que saltan a Top 200 presentan mayor *momentum* temprano en Spotify.

- Los resultados confirman esta hipótesis de forma contundente. Las seis features de Charts (basadas en posición y trayectoria dentro de Viral 50) concentran aproximadamente el 60% de la importancia acumulada del modelo.
- Las tres variables más predictivas son **days_on_viral** (0.138), **mean_rank** (0.128) y **best_rank** (0.110). Esto revela que la permanencia en el chart viral y la calidad de la posición alcanzada son las señales más fuertes para anticipar la consolidación. La variable **rank_slope** (0.091), que captura si el track mejora o empeora su posición a lo largo del tiempo, complementa este hallazgo. Cuando un track que no solo permanece al chart Viral sino que mejora su posición tiene mayor probabilidad de saltar. El clustering (k=3) refuerza esta lectura: el Cluster 2 (permanencia alta de ~44 días, rango amplio) tiene hit rate de 20%, mientras que el Cluster 0 (permanencia baja de ~11 días) apenas alcanza 7%.
- **H2** proponía que las métricas de YouTube aportan señal incremental frente a usar solo Spotify y audio.
 - Los resultados respaldan parcialmente esta hipótesis. Las cinco features de YouTube contribuyen aproximadamente un 18% de la importancia total, con **yt_max_comments** (0.039) y **yt_comment_ratio** (0.037) como las más relevantes del grupo. Que las métricas de comentarios superen a las de vistas, sugiere que la discusión activa (engagement participativo) es una señal más fuerte que el consumo “pasivo” de video.
 - La contribución de YouTube está limitada por la cobertura del matching (47.1%): para el 53% de los tracks sin match, estas features fueron igualadas a cero, diluyendo su peso real. En un escenario con cobertura completa de match entre video y canción (por ejemplo, usando ISRC como llave de enlace), la señal de YouTube probablemente sería sustancialmente mayor.
- **H3** planteaba la existencia de perfiles diferenciados de canciones con distinta probabilidad de consolidación dependiendo de alguna característica específica de comportamiento o dependiendo de sus atributos musicales.
 - Los tres clusters obtenidos por K-Means (silhouette = 0.43) confirman esta hipótesis y revelan patrones interpretables.
 - **El Cluster 0** (ranking bajo, poca permanencia en Viral) agrupa la mayoría de los tracks (308) y con el menor hit rate del 7%.
 - **El Cluster 1** (ranking alto, permanencia breve en Viral) muestra hit rate de 19%, sugiriendo que algunos tracks entran con fuerza realmente no necesitan permanencia prolongada para consolidarse en el top 200.
 - **El Cluster 2** (ranking alto, permanencia alta, rango amplio de movimiento en Viral) es el más interesante para la aplicación práctica: tiene hit rate de 20% y contiene 244 tracks, lo que lo convierte en el segmento más grande con alta probabilidad. Sin embargo, la hipótesis específica de que el perfil sonoro (alta energía + alto engagement) determinaría la propensión no pudo

verificarse, ya que las audio features mostraron baja importancia predictiva individual (~15% acumulado).

Interpretación del modelo como herramienta de priorización

El hallazgo central de este proyecto es que el modelo funciona mejor como “rankeador” que como clasificador binario. Con el umbral por defecto (0.5), **Gradient Boosting** en test tiene recall de solo 10.7% y F1 de 0.167, métricas que parecerían insuficientes para un sistema predictivo. Sin embargo, al evaluar el modelo como herramienta de priorización mediante Precision@K, los resultados cambian radicalmente: P@5 = 0.60 en test implica que 3 de cada 5 canciones priorizadas efectivamente saltan al Top 200, lo cual representa un rendimiento cuatro veces superior a la selección aleatoria (13.5%). Incluso a P@30, la precisión se mantiene en 0.30 (x2 veces el azar).

Esta lectura con Precision@K se puede alinear de forma muy coherente con el caso de uso real en la industria musical. Un equipo de A&R o Marketing no necesita clasificar correctamente todas las canciones del frontline (canciones nuevas), sólo necesita una lista corta de apuestas con alta probabilidad de éxito. En ese contexto, un modelo que permite seleccionar 5-10 canciones con precisión del 40-60% representa una ventaja operativa significativa frente a la sólo trabajar con intuición. Indudablemente en la industria musical se necesita mucha intuición para tomar las decisiones correctas, sin embargo, si apoyamos esa intuición con sugerencias extras de posibles éxitos mediante un método heurístico de machine learning, los stakeholders tendrán una poderosa herramienta que los pondrá un paso adelante en el mercado versus la competencia que no se apoya de estas herramientas de alto nivel de cómputo.

Limitaciones del estudio

1. La principal limitación es el tamaño del dataset. De los 1,045 tracks con solo 141 positivos (13.5%) limita tanto la capacidad del modelo como la robustez estadística de las métricas. En el conjunto de test, hay apenas 28 positivos, lo que significa que mover 2-3 predicciones altera significativamente las métricas, como se observó cuando Random Forest superó a Gradient Boosting en ROC-AUC de test (0.743 vs 0.719) a pesar de ser inferior en validación.
2. La cobertura parcial de fuentes externas introduce un sesgo sistemático. Las audio features sólo cubren el 20% de los tracks y YouTube el 47%. Para el 80% de tracks sin audio features, los valores se calcularon con la mediana, lo que neutraliza su señal y reduce artificialmente su importancia relativa. Las flags binarias (has_audio_features, has_youtube_match), diseñadas para capturar la presencia entre dataset como señal en sí misma, mostraron importancia baja (<0.01 cada una), sugiriendo que el hecho de tener o no match no es predictivo per se, sino que lo relevante es el valor de las features cuando están disponibles.

3. El emparejamiento Spotify-YouTube por similitud de texto (título y artista) puede introducir falsos positivos en el matching. El proyecto intenta mitigar este riesgo aplicando limpieza de texto y matching en tres niveles progresivos, pero la ausencia de una llave universal (como el código ISRC) impide garantizar la precisión perfecta.
4. La ventana temporal (agosto 2020 - noviembre 2021) incluye el periodo pandémico, durante el cual los patrones de consumo musical pudieron diferir de años típicos. La generalización a otros periodos requeriría re-entrenamiento y validación adicional.

Comparación con la literatura

Los resultados son consistentes con la evolución del campo de *Hit Song Science*.

- Pachet y Roy (2008) concluyeron que la predicción de hits no era aún científica, en gran parte porque se basaba exclusivamente en audio features.
- Ni, Y. (2011) muestra que incorporar características adicionales mejoraba sustancialmente los modelos.
- Nuestros resultados confirman esta trayectoria: las audio features por sí solas tienen baja importancia (~15%), pero la combinación de señales de comportamiento (Charts), audio y engagement social (YouTube) permite alcanzar ROC-AUC de 0.72, superando significativamente al azar.
- La importancia dominante de las features de comportamiento en charts sobre las features intrínsecas de audio es coherente con Herremans et al. (2014), quienes también encontraron que las características de consumo superan a las acústicas en tareas de predicción de hits.

14. Resultados

Resultados del modelo predictivo

El proyecto logró construir un sistema de detección temprana funcional que predice la transición de canciones de Viral 50 MX → Top 200 MX con desempeño superior al azar. De los cuatro modelos evaluados, **Gradient Boosting** fue seleccionado como modelo final con ROC-AUC = 0.724 en validación y 0.719 en test, confirmando estabilidad entre particiones. La consistencia entre ambos conjuntos (diferencia de apenas 0.005) indica que el modelo generaliza adecuadamente y no presenta sobreajuste.

El resultado más relevante para la aplicación práctica es el desempeño como herramienta de priorización. En el conjunto de test, el modelo alcanzó Precision@5 = 0.60 (3 de 5 canciones priorizadas efectivamente se convierten en hits), Precision@10 = 0.40 y Precision@30 = 0.30. Estas cifras representan entre x2 y x4 veces mayor al rendimiento esperado de la selección aleatoria (baseline = 13.5%), demostrando valor incremental significativo como herramienta de apoyo a la toma de decisiones.

Variables más relevantes

El análisis de importancia de variables (Random Forest) reveló una jerarquía clara entre las fuentes de datos. Las features de Spotify Charts dominan la predicción con aproximadamente 60% de la importancia acumulada, lideradas por **days_on_viral** (14%), **mean_rank** (13%) y **best_rank** (11%). Le siguen las features de YouTube con 18% (destacando **yt_max_comments** y **yt_comment_ratio**), y las audio features con 15%.

Este resultado tiene una implicación práctica directa: la señal más fuerte para predecir si una canción se consolidará como **hit** proviene de su propia trayectoria dentro del chart viral. Una canción que permanece muchos días en Viral 50 y mantiene buena posición tiene alta probabilidad de saltar. Las métricas de comentarios en YouTube añaden señal complementaria, mientras que las características acústicas intrínsecas (danceability, energy, valence) tienen peso individual bajo, sugiriendo que “cómo suena” una canción importa menos que “cómo se comporta” en plataformas digitales para predecir su consolidación.

Segmentación de comportamientos

El análisis no supervisado identificó tres perfiles de canciones con probabilidades diferenciadas de consolidación.

1. El perfil de “paso fugaz” (Cluster 0 con 308 tracks) agrupa canciones con posición baja y permanencia corta, con hit rate de solo 7%.
2. El perfil de “estrella instantánea” (Cluster 1 con 75 tracks) incluye canciones que entran en posiciones altas pero desaparecen rápido, con hit rate de 19%.
3. El perfil de “ascenso sostenido” (Cluster 2 con 244 tracks) describe canciones con buena posición, alta permanencia y rango amplio, con hit rate de 20%. Este último segmento es el de mayor interés operativo: contiene el mayor volumen de tracks con alta probabilidad, lo que lo convierte en el grupo prioritario para inversión.

Entregables del proyecto

El proyecto produce los siguientes entregables concretos:

1. Un dataset analítico integrado de 1,045 tracks con 23 features provenientes de tres fuentes, disponible en formato Parquet subidos en Github para reproducción.
2. Un pipeline completo de preprocesamiento, matching multifuente e ingeniería de características documentado en Google Colab.
3. Cuatro modelos supervisados entrenados y evaluados con métricas formales, con **Gradient Boosting** como modelo seleccionado.

4. Un análisis descriptivo documentado en formato PDF, explicando los findings de segmentación según los perfiles de comportamiento viral.

15. Conclusiones y Recomendaciones

Conclusiones

Este proyecto demostró que es viable construir un modelo de detección temprana de hits en México combinando datos públicos de Spotify Charts, audio features y YouTube Trending. El modelo **Gradient Boosting** alcanzó ROC-AUC de 0.72, consistente entre validación y test, superando significativamente tanto la línea base aleatoria como los modelos lineales simples.

La conclusión más importante es que el modelo tiene mayor valor como herramienta de priorización que como clasificador binario. Un F1 de 0.167 puede parecer bajo en términos académicos, pero $\text{Precision@5} = 0.60$ en test significa que 3 de cada 5 canciones del top recomendado se convierten en *hit*, lo cual es directamente accionable para un equipo de A&R o Marketing. Encontrar que el modelo sirve como un sistema de ranking, más que como predictor binario, es la contribución clave del proyecto al problema de negocio planteado, a pesar de que la propuesta en la fase inicial era enfocarse en el poder binario del modelo.

Se confirmó que la trayectoria de comportamiento dentro de Viral 50 (permanencia, posición y tendencia) es la señal más fuerte para anticipar la consolidación, por encima de las características acústicas y de las métricas de YouTube. Esto sugiere que la viralidad sostenida, no la instantánea, es el mejor predictor de éxito masivo.

Recomendaciones

Para atacar esta oportunidad de forma “rápida” se puede recomendar un monitoreo sistemático de permanencia en Viral 50. La variable más predictiva es **days_on_viral**. Se puede implementar un dashboard que alerte cuando un track supere un umbral de permanencia (por ejemplo, 14 días) combinado con posición promedio en el top 20, ya que estos tracks tienen probabilidad significativamente elevada de saltar al Top 200.

A pesar de contar con un dataset muy pequeño se recomienda el uso del modelo presentado como priorizador de inversión. En lugar de intentar predecir todos los hits, se puede utilizar el modelo para generar un Top-5 o Top-10 semanal de canciones con mayor probabilidad. Los resultados muestran que esta lista corta tiene precisión del 40%-60%, suficiente para justificar la asignación de recursos de marketing, playlisting o pauta digital de forma temprana. Siempre de la mano con la intuición y el conocimiento del negocio.

Activación de YouTube como palanca anticipada. Los comentarios en YouTube resultaron ser la señal de engagement más predictiva de la plataforma, por encima de vistas y likes. Esto sugiere que fomentar discusión y participación activa (no solo views) puede ser una palanca estratégica para amplificar la trayectoria de una canción durante su fase viral.

Trabajo futuro

Para mejorar el modelo se recomienda:

1. Ampliar la ventana temporal a múltiples años para incrementar el tamaño de la muestra y verificar la estabilidad del modelo fuera del periodo pandémico.
2. Utilizar ISRC (International Standard Recording Code) como llave de enlace entre Spotify y YouTube para eliminar el ruido del matching por similitud de texto y alcanzar cobertura cercana al 100%.
3. Incorporar features de redes sociales adicionales (TikTok, Instagram Reels) que han cobrado relevancia como amplificadores virales.
4. Explorar modelos de series temporales que capturen la dinámica diaria del ranking en lugar de trabajar con agregados estáticos.
5. Implementar el modelo como servicio automatizado que se alimente diariamente de los charts publicados por Spotify y genere recomendaciones en tiempo real.

Referencias Electrónicas y Fuentes de Datos

I. Artículos científicos

1. **Pachet, F., & Roy, P. (2008). *Hit Song Science is Not Yet a Science*.**
9th International Conference on Music Information Retrieval (ISMIR 2008).
URL: http://ismir2008.ismir.net/papers/ISMIR2008_133.pdf
2. **Ni, Y., Santos-Rodríguez, R., McVicar, M., & De Bie, T. (2011). *Hit song science once again a science*.**
Proceedings of the 4th International Workshop on Machine Learning and Music (MML 2011).
URL: https://www.academia.edu/18863015/Hit_Song_Science_Once_Again_a_Science
3. **Herremans, D., Martens, D., & Sörensen, K. (2014). *Dance hit song prediction*.**
Advances in Data Analysis and Classification, 8(2), 297-307.
URL: <https://arxiv.org/abs/1905.08076>
4. **Yee, J. L. Y., & Raheem, A. A. (2022). *Predicting music popularity using Spotify and YouTube features*.**
Indian Journal of Science and Technology, 15(36).
URL: <https://doi.org/10.17485/IJST/v15i36.2332>

II. Datasets públicos a utilizar para el proyecto

1. **Spotify Charts (Top 200 & Viral 50) - Kaggle**
URL: <https://www.kaggle.com/datasets/dhruvildave/spotify-charts>
2. **Spotify 1.2M Songs - Audio Features - Kaggle**
URL: <https://www.kaggle.com/datasets/rodolfofigueroa/spotify-12m-songs>
3. **YouTube Trending Video Dataset - Kaggle**
URL: <https://www.kaggle.com/datasets/rsrishav/youtube-trending-video-dataset>

4. **Spotify and YouTube: A Dynamic Dataset for Comprehensive Music Analysis** - Kaggle

URL: <https://www.kaggle.com/datasets/salvatorerastelli/spotify-and-youtube>

5. **Spotify Top 50 Songs in 2021** - Kaggle

URL: <https://www.kaggle.com/datasets/equinxx/spotify-top-50-songs-in-2021>